第一次编程作业

1 任务说明

本次作业通过核心算法实现和对照实验，理解模型假设、超参数与数据特性如何影响学习效果，并据此判断模型的适用条件。请从以下四种算法中选择两种，实现其核心过程并进行比较。

- K 近邻算法（K-Nearest Neighbors, K-NN）
- 支持向量机（Support Vector Machine, SVM；可实现线性软间隔 SVM）
- 决策树（Decision Tree，如 ID3、C4.5 或 CART）
- 逻辑回归（Logistic Regression）

两种算法均须完成以下合成数据和真实数据实验。

1.1 合成数据集实验

自行编写代码生成至少三种合成数据设置，两种算法使用相同的数据进行比较。围绕一个明确问题，控制数据分布、样本量、噪声或无关特征等因素，观察算法表现如何变化。实验前说明预期，实验后结合结果解释模型的适用条件与局限；结果不必符合预期。

1.2 真实数据集实验

从以下数据集中至少选择一个，使用相同的训练 / 验证 / 测试划分比较两种算法。允许根据计算资源使用固定随机种子抽取的子集，须说明样本量与抽样方式，并保证比较公平。

- **Webspam 数据集（unigram 版本）**

  网页垃圾 / 非垃圾二分类，采用发布方已提取的数值特征。课程文件从公开版 350,000 条记录中固定抽取 30,000 条，含 254 个特征，保留原分类任务。

  来源：Webspam Dataset @ LIBSVM Data

  下载：https://cloud.tsinghua.edu.cn/f/d74b2775a14848f79281/?dl=1

- **HEPMASS 数据集（固定质量 1000 版本）**

  从高能物理模拟背景事件中识别信号事件。课程文件使用官方质量 1000 版本的前 500,000 条训练记录，含 27 个特征，保留原二分类标签。

  来源：HEPMASS Dataset @ UCI Machine Learning Repository

  下载：https://cloud.tsinghua.edu.cn/f/99743ae0739b42c39b85/?dl=1

2 任务和报告要求

a）核心实现与工具使用。两种算法的核心训练与预测过程须自行实现，不得直接调用现成模型代替；可使用 NumPy 等基础工具。允许使用 Codex 等 AI 工具辅助，须简述用途，并能解释、修改和验证提交的核心代码。参考资料须注明来源，报告中给出一个实现正确性的检查。

b）合成数据分析。说明实验问题、预期和控制变量，比较两种算法在不同数据设置下的表现，并结合模型假设解释结果。合理且有分析的失败实验同样有价值。

c）参数与模型选择。在真实数据上展示关键超参数的比较过程，使用验证集选择参数，测试集仅用于最终评估。预处理所需统计量仅由训练集估计。报告训练与验证指标随超参数的变化，并说明评价指标的选择理由。

d）算法机制展示。每种算法至少展示一组二维合成数据上的决策边界并解释其形状；另选一个算法细节深入展示，如邻居选择、树的划分、SVM 间隔或梯度更新，说明其如何影响结果。决策边界可通过在二维网格上预测类别并着色绘制。

e）适用性判断。根据实验说明：在什么条件下你会选择哪种算法，其局限是什么，条件怎样变化时需要重新考虑。可结合预测效果、计算成本或可解释性讨论，避免仅列出通用优缺点。

f）提交要求。提交不超过八页的 PDF 报告及代码，注明运行方法与随机种子，建议使用 Python。评价重点为实现正确性、实验设计、分析证据和适用性判断，不以最高准确率为唯一依据。